

Lab 05: Apache Spark

Mục tiêu:

- Cài đặt môi trường sử dụng Apache Spark
- Triển khai thử nghiệm Apache Spark examples.
- Triển khai chạy thử nghiệm Spark RDD
- Triển khai chạy thử nghiệm Spark SQL
- Kiểm tra kết quả thực hiện trên màn hình giao diện ứng dụng, xem tiến trình của tác vụ trong bảng điều khiển và một URL để xem thông tin chi tiết hơn về tác vụ.
- Submit kết quả thực hiện Project lên hệ thống (LMS Canvas, Github, jupyter notebook...)


Nội dung:

1. Cài đặt môi trường sử dụng Apache Spark

Cài đặt qua docker:

- `docker pull jupyter/pyspark-notebook`
- `docker run -p 8888:8888 jupyter/pyspark-notebook`
- <http://127.0.0.1:8888/tree> hoặc
- <http://192.168.99.100:8888/tree> trên Windows
- Điền token key thích hợp
- Upload thư mục notebook vào container

Sử dụng PySpark trong Colab



▼ Setting up PySpark in Colab

Spark is written in the Scala programming language and requires the Java Virtual Machine (JVM) to run. Therefore, our first task is to download Java.

```
!apt-get install openjdk-8-jdk-headless -qq > /dev/null
```

Next, we will install Apache Spark 3.0.1 with Hadoop 2.7 from here.

```
!wget https://downloads.apache.org/spark/spark-3.1.1/spark-3.1.1-bin-hadoop2.7.tgz

--2021-03-21 15:52:56-- https://downloads.apache.org/spark/spark-3.1.1/spark-3.1.1-bin-hadoop2.7.tgz
Resolving downloads.apache.org (downloads.apache.org)... 88.99.95.219, 2a01:4f8:0:1::1
Connecting to downloads.apache.org (downloads.apache.org)|88.99.95.219|:443... connected
HTTP request sent, awaiting response... 200 OK
Length: 224374704 (214M) [application/x-gzip]
Saving to: 'spark-3.1.1-bin-hadoop2.7.tgz'

spark-3.1.1-bin-had 100%[=====>] 213.98M  19.0MB/s   in 12s

2021-03-21 15:53:08 (17.8 MB/s) - 'spark-3.1.1-bin-hadoop2.7.tgz' saved [224374704]
```

Now, we just need to unzip that folder.

```
!tar xf spark-3.1.1-bin-hadoop2.7.tgz
```

2. Triển khai thử nghiệm Apache Spark examples

Spark is a great engine for small and large datasets. It can be used with single-node/localhost environments, or distributed clusters. Spark's expansive API, excellent performance, and flexibility make it a good option for many analyses. This guide shows examples with the following Spark APIs:

- DataFrames
- SQL
- Structured Streaming
- RDDs

3. Thực hiện nội dung về Spark RDD (file đính kèm)

4. Thực hiện nội dung về Spark SQL (file đính kèm)

5. Thực hiện so sánh kết quả triển khai bài toán Wordcount với MapReduce Hadoop và Spark RDD

You would like to compute the count of each word in the text file.
Here is how to perform this computation with Spark RDDs:


```
text_file = spark.sparkContext.textFile("some_words.txt")

counts = (
    text_file.flatMap(lambda line: line.split(" "))
    .map(lambda word: (word, 1))
    .reduceByKey(lambda a, b: a + b)
)
```

Let's take a look at the result:


```
counts.collect()

[('these', 2),
 ('are', 2),
 ('more', 1),
 ('in', 1),
 ('words', 3),
 ('english', 1)]
```



```
Command Prompt
Microsoft Windows [Version 10.0.10240]
(c) 2015 Microsoft Corporation. All rights reserved.

C:\Users\dachi>hdfs dfs -cat /output/part-r-00000
BUS      2
Bus      1
CAR      1
Car      1
TRAIN    2
buS      1
bus      3
caR      1
car      4
train    2
```



6. Hoàn thành và submit project trên LMS